다음 시험에서 나는 몇 점을 받을까?

Code States
Section1 Project
AI_14_이미리

분석 목차

1. 문제 정의

2. EDA(데이터 전처리)

3. 모델링

4. 분석 결과

1. 문제 정의

1. 문제 정의

가설 : 수강생의 과거 정오표 데이터를 통해
다음 시험 정/오답을 예측할 수 있다.

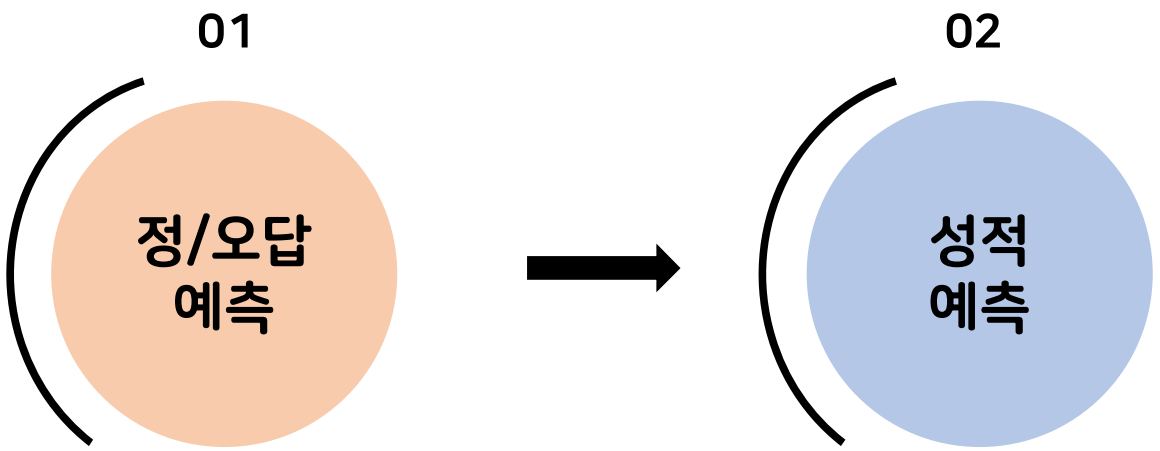

-> 취약 유형 파악

-> 성적 향상 가능

2. EDA(데이터 전처리)

2. EDA(데이터 전처리)

1. 문항 IRT

- testID : 시험지ID
- assessmentItemID : 문제 ID
- difficultyLevel : 난이도 (-5~5)
- discriminationLevel : 변별도 (0~∞)
- guessLevel : 추측도(0~1)
- Timestamp : 데이터 생성 일자
- knowledgeTag : 지식체계번호

2. 학생 IRT

- learnerID : 학생 ID
- learnerProfile : 학생 정보
- testID : 시험지 ID
- theta : testID 에 대한 응시자의 능력 수준(-5~5)
- realScore : 진점수
- Timestamp : 데이터 생성 일자

3. 문항 정오답표

- learnerID : 학생 ID
- learnerProfile : 학생 정보 (Gender;학년등급;학년)
- testID : 시험지 ID
- assessmentItemID : 문제 ID
- answerCode : 채점결과 (0:틀림, 1:맞음)
- Timestamp : 응시 일자

2. EDA(데이터 전처리)

4. 문항 IRT + 학생 IRT

- learnerID : 학생 ID
- testID : 시험지 ID
- assessmentItemID : 문제 ID
- answerCode : 채점결과 (0:틀림, 1:맞음)
- testID : 시험지ID
- assessmentItemID : 문제 ID
- difficultyLevel : 난이도 (-5~5)
- discriminationLevel : 변별도 (0~∞)
- guessLevel : 추측도(0~1)
- knowledgeTag : 지식체계번호
- theta : testID 에 대한 응시자의 능력 수준(-5~5)
- realScore : 진점수

3. 문항 정오답표

- learnerID : 학생 ID
- learnerProfile : 학생 정보 (Gender;학년등급;학년)
- testID : 시험지 ID
- assessmentItemID : 문제 ID
- answerCode : 채점결과 (0:틀림, 1:맞음)
- Timestamp : 응시 일자

2. EDA(데이터 전처리)

- theta : testID 에 대한 응시자의 능력 수준(-5~5)
- realScore : 진점수
- difficultyLevel : 난이도 (-5~5)
- discriminationLevel : 변별도 (0~∞)
- guessLevel : 추측도(0~1)
- knowledgeTag : 지식체계번호
- gender (female:1, male:0)
- grade (1~9)

- answerCode : 채점결과 (0:틀림, 1:맞음)

Target

3. 모델링

3. 모델링

target = answerCode


```
# 기준모델 mode
major = y_train.mode()[0]
y_pred=[major]*len(y_train)

from sklearn.metrics import accuracy_score
print('검증 정확도: ', accuracy_score(y_train, y_pred))

#기준모델의 검증 정확도 66%
```

```
검증 정확도:  0.6613375400720307
```

검증 정확도 : 0.661

기준모델 : mode(최빈값)

시간 순서 정렬 후,
최근 데이터 20% test 셋 생성,
남은 데이터의 최근 20% val 셋 생성

3. 모델링

1. xgboost

```
from xgboost import XGBClassifier
from sklearn.pipeline import make_pipeline

pipe2 = make_pipeline(XGBClassifier(n_jobs=-1,
                                    learning_rate=0.2))
pipe2.fit(X_train, y_train)

y_pred2 = pipe2.predict(X_val)
print('xgboost 검증 정확도: ', accuracy_score(y_val, y_pred2))
```

```
xgboost 검증 정확도:  0.8649572565005739
```

검증 정확도 : 0.865

2. RandomForest

```
from sklearn.ensemble import RandomForestClassifier


pipe = make_pipeline(
    RandomForestClassifier(n_jobs=-1, random_state=28, oob_score=True)
)

pipe.fit(X_train, y_train)

y_pred = pipe.predict(X_val)
print('Random Forest 검증 정확도: ', accuracy_score(y_val, y_pred))
```

```
Random Forest 검증 정확도:  0.9320135948074564
```

검증 정확도 : 0.932

3. 모델링

특성중요도

1. realScore
2. theta
3. difficultyLevel
4. discriminationLevel
5. guessLevel

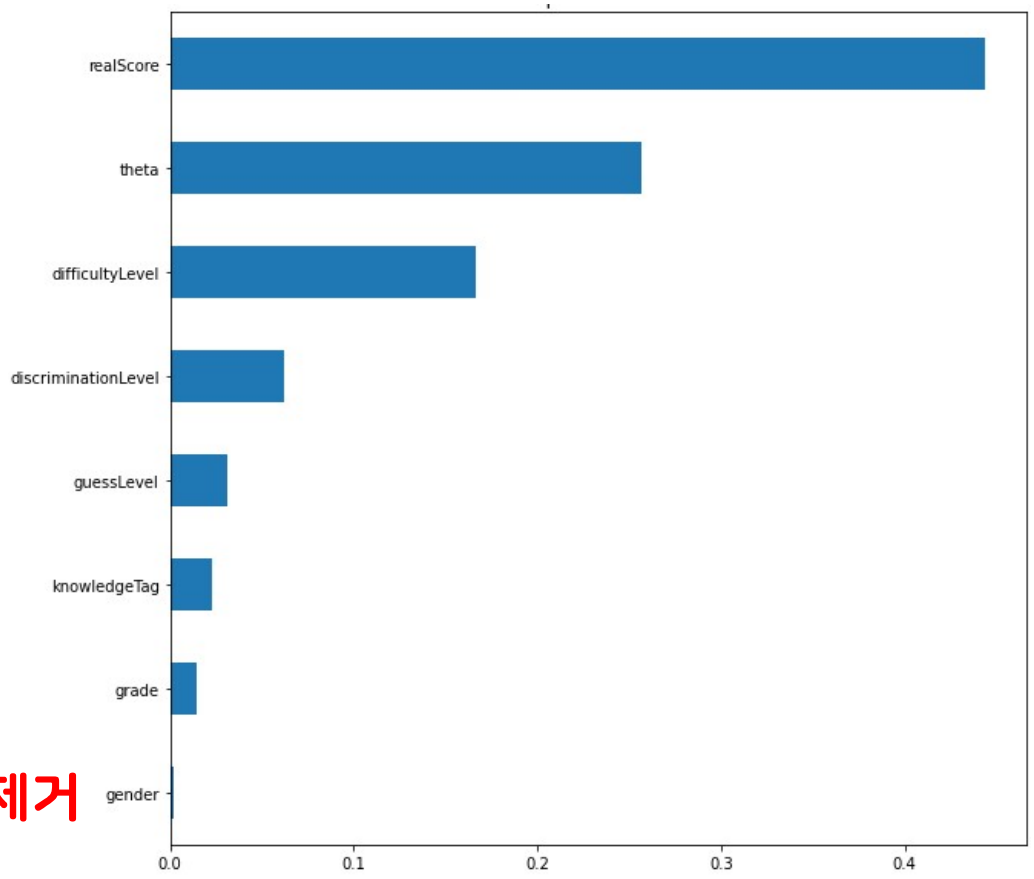

gender 제거

3. 모델링

최적의 하이퍼파라미터 찾기

max_depth = 20
max_features = 0.7273
n_estimators = 52

```
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint, uniform

dists = {
    'randomforestclassifier__n_estimators': randint(50, 500),
    'randomforestclassifier__max_depth': [5, 10, 15, 20, None],
    'randomforestclassifier__max_features': uniform(0, 1)
}

clf = RandomizedSearchCV(
    pipe,
    param_distributions=dists,
    n_iter=2,
    cv=2,
    scoring='accuracy',
    verbose=1,
    n_jobs=-1
)

clf.fit(X_train, y_train);
```

```
print('최적 하이퍼파라미터: ', clf.best_params_)
print('MAE: ', -clf.best_score_)
```

```
최적 하이퍼파라미터:  {'randomforestclassifier__max_depth': 20, 'randomforestclassifier__max_features': 0.7273335939652188, 'randomforestclassifier__n_estimators': 52}
MAE:  -0.9185752414216171
```

3. 모델링

최적의 하이퍼파라미터 검증

```
from sklearn.ensemble import RandomForestClassifier


pipe3 = make_pipeline(
    RandomForestClassifier(n_jobs=-1, random_state=54, oob_score=True, max_depth=20, min_samples_leaf=2,min_samples_split =4, n_estimators=52, max_features=0.7273335939652188)
)

pipe3.fit(X_train, y_train)

y_pred3 = pipe3.predict(X_val)
print('Random Forest 검증 정확도: ', accuracy_score(y_val, y_pred3))
```

```
Random Forest 검증 정확도:  0.9231260141686786
```

검증 정확도 : 0.923

4. 분석결과

4. 분석 결과 (PDP)

1. realScore

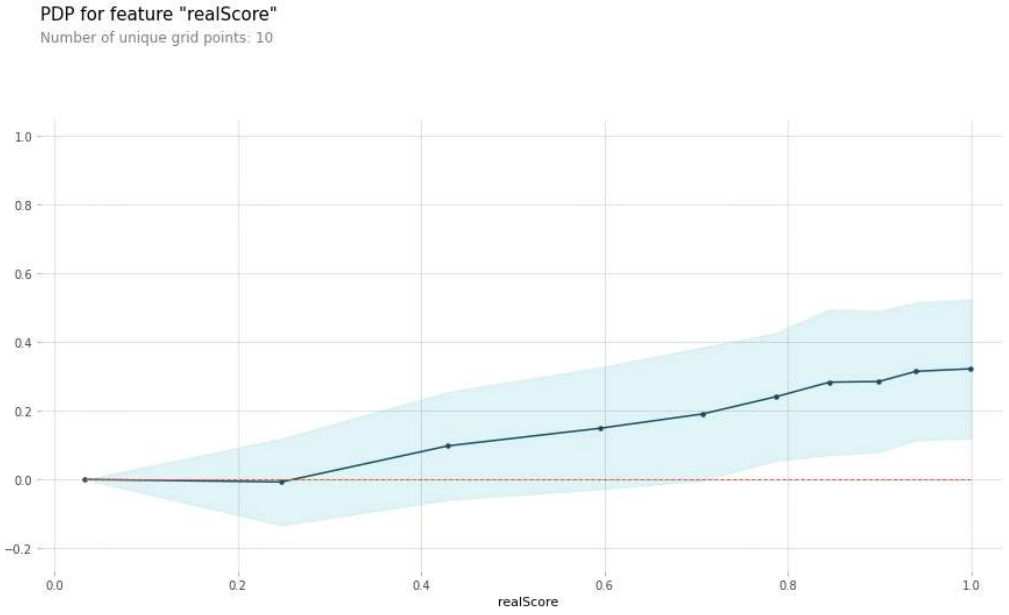

2. theta

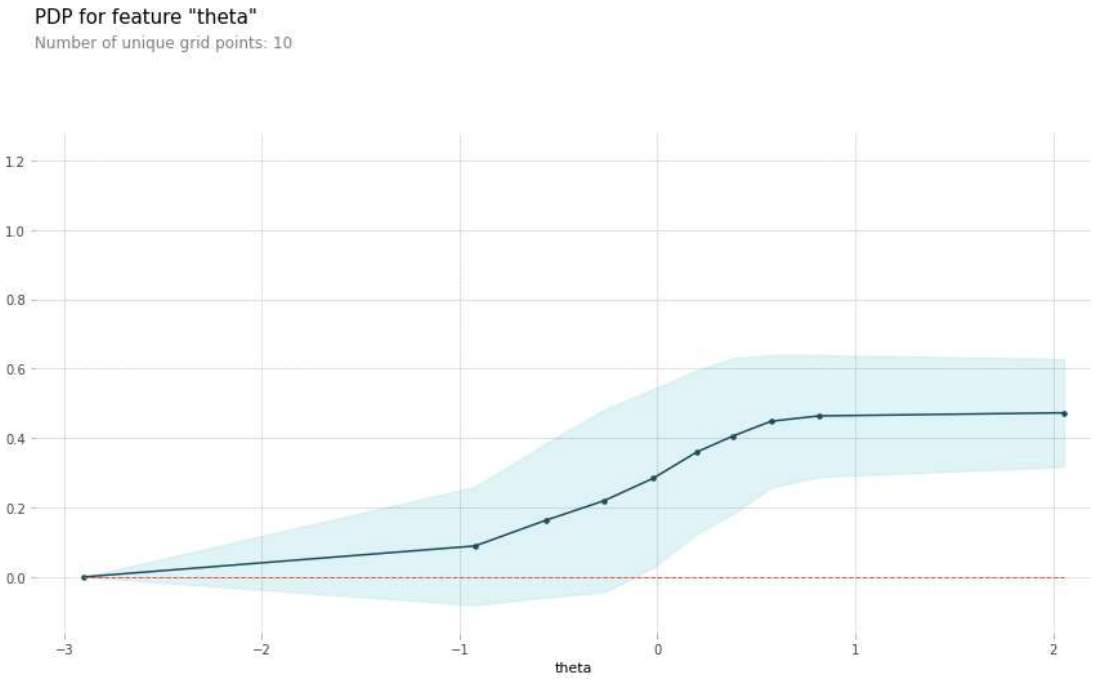

4. 분석 결과 (PDP)

3. difficultyLevel

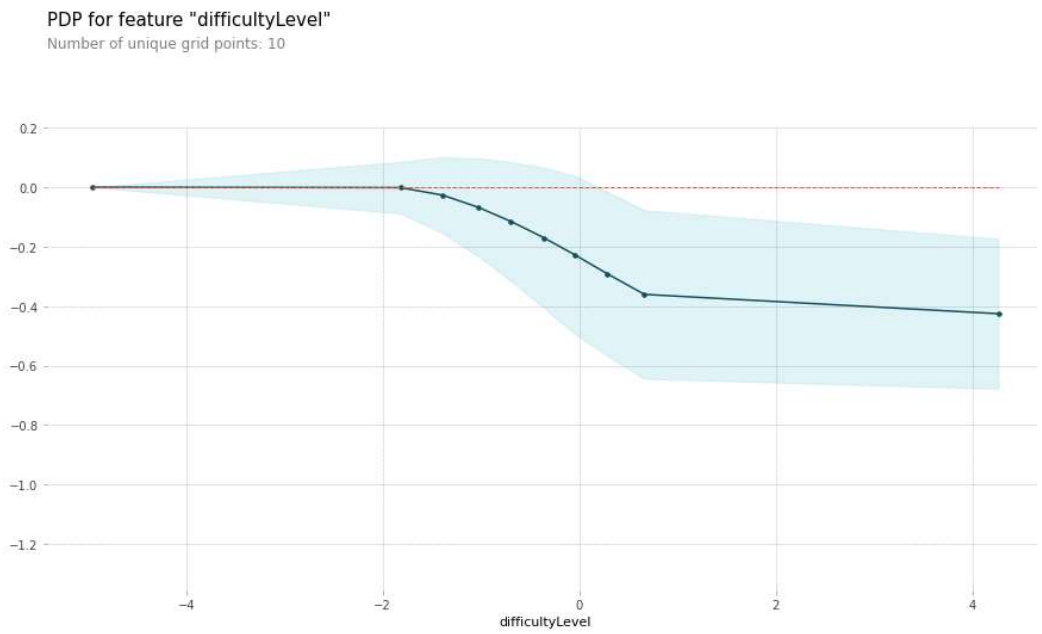

4. guessLevel

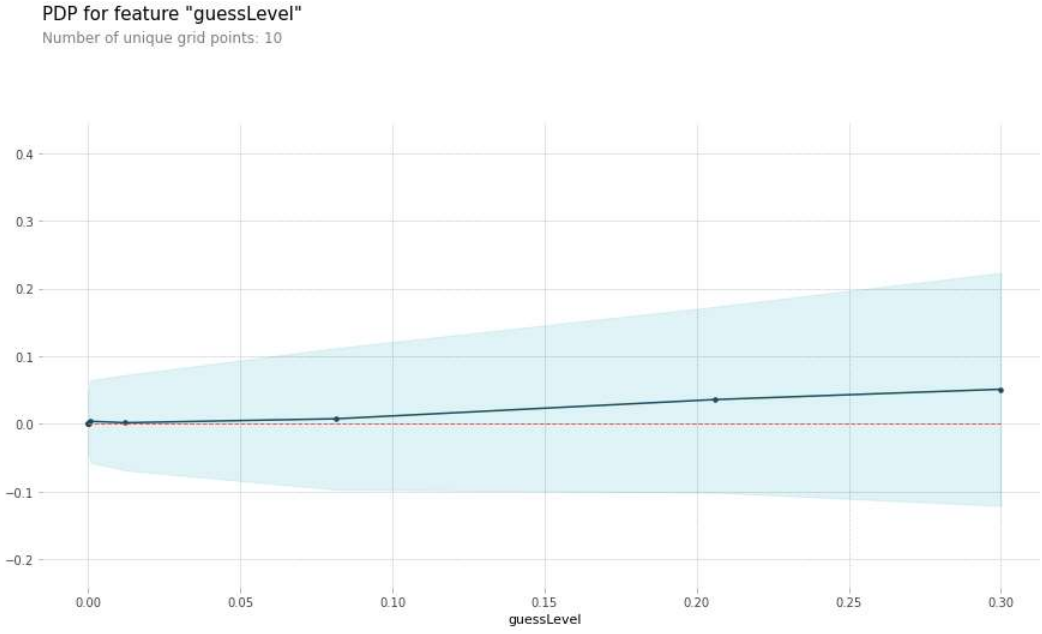

4. 분석 결과

1) 문항 정/오답을 93% 예측 가능한 모델 생성

2) 진점수, 응시자의 능력 수준이 높을 수록 문항 정답 확률 UP!

3) 문제의 난이도가 높을 수록 문항 정답 확률 DOWN!

더 발전해야 할 점

1) 이전 시험의 진점수를 반영하도록 수정

2) 전체가 아닌 개개인의 수강생 ID 를 반영하여 개인에 대한 분석

3) 분석 환경 및 효율성 개선

감사합니다.